

《Generative Adversarial Nets》

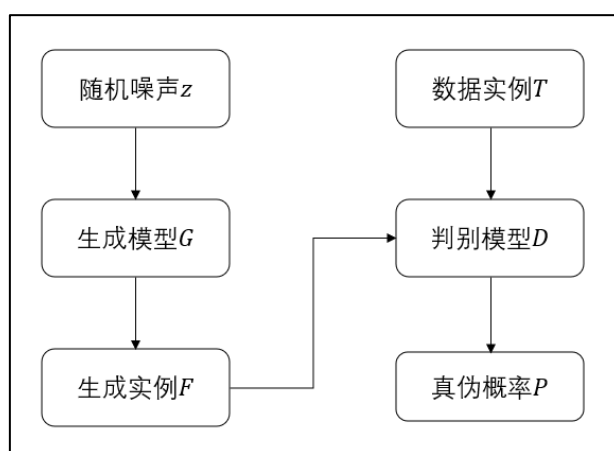
摘要：

1. **论文背景：**深度学习已经在判别模型中取得了一系列较好的成果，但在生成模型领域中尚未有优秀、合适的框架被提出。
2. **论文的贡献：**提出了一个通过对抗过程来估计生成模型的新神经网络框架，它包含两个训练模型：**模拟数据分布的生成模型 G** 和 **判别样本数据真假的判别模型 D**。
3. **主要创新点：**所提出的架构可以有效使用反向传播来进行训练，而不需要运用任何类似“马尔科夫链”复杂的推理网络。此外，框架还结合了一定的博弈理论。
4. **实验分析：**论文中简单证明了对抗性建模框架（**生成对抗网络**）的可行性，并且表明了这些研究方向可能是有用的。【该框架如今已被广泛使用】

GAN 网络整体框架：

在 GAN 中包含有两个模型，一个是**生成模型 G (Generative model)**，一个是**判别模型 D (Discriminative model)**。生成模型 G 的任务是生成看起来自然真实的、和原始数据相似的实例；而判别模型 D 的任务是判断给定的实例看起来是自然真实的，还是人为伪造的（真实实例来源于数据集，伪造实例来源于生成模型 G）。

具体网络结构如图所示：



- 1) **生成模型 G：**G 是一个生成伪造实例的网络，它首先接收一个随机的噪声 z ，然后通过这个噪声来生成伪造（生成）实例 F ，记做 $G(z)$ 。

2) **判别模型 D**: D 是一个用于判别网络, 其主要功能就是判别一个实例是不是“真实的”。它的输入是 x (x 代表一个实例), 输出是 $D(x)$, 它代表 x 为真实实例 T 的概率 P 。如果 $P = 1$, 则代表 100% 是真实实例; 而如果 $P = 0$, 则代表不可能是真实实例。

注意: 这里的网络是指 MLP (多层感知器)。

GAN 模型优化训练:

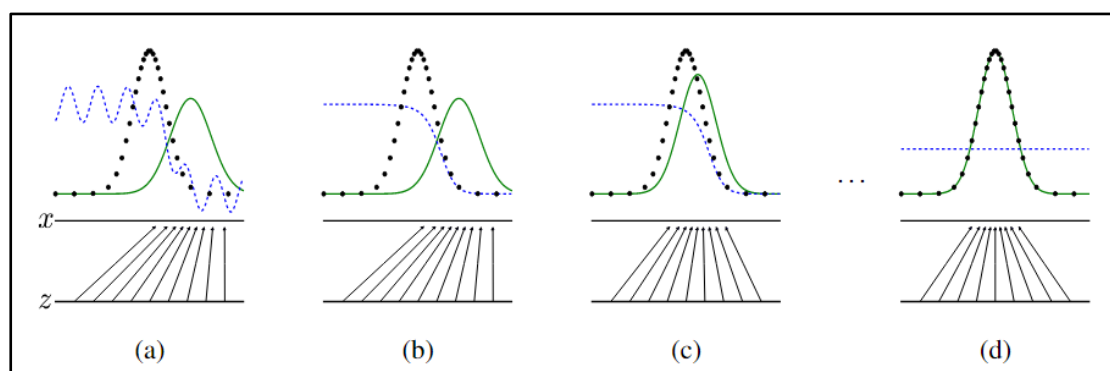
GAN 的目标优化函数如下:

$$\min_G \max_D V(D, G) = \mathbb{E}_{\mathbf{x} \sim p_{\text{data}}(\mathbf{x})} [\log D(\mathbf{x})] + \mathbb{E}_{\mathbf{z} \sim p_{\mathbf{z}}(\mathbf{z})} [\log(1 - D(G(\mathbf{z})))]$$

训练的目标就是优化判别网络 D , 使得最大概率地对训练样本的标签 (即最大化 $\log D(x)$ 和 $\log(1 - D(G(z)))$); 优化生成网络 G , 使得最小化 $\log(1 - D(G(z)))$, 即最大化 D 的损失。

而在训练过程中, 首先固定一方网络, 然后再更新另一个网络的参数, 并交替迭代, 使得对方的错误最大化【类似于博弈过程】。最终, 生成模型 G 就能估测出样本数据的分布, 即使得生成的样本更加真实。

对抗过程可视化:



如图所示, 在模型的对抗训练中, 可能会出现以上几种情况:

图(a): D (蓝色线) 刚开始训练, 其本身判别能力有限, 结果存在波动, 但还是能初步区分实际数据和生成数据。

图(b): 在 D 经过有效训练后, 可以明显地区分出生成数据。

图(c): G 优化自己的输出分布 (绿色线), 使得其更加接近真实数据的分布 (黑色线), 从而使得 D 更加难以判别实际数据和生成数据。

图(d): 由于 G 的不断提升, 其输出分布几乎已经等同于真实数据的分布, 从而使得 D 难以判别二者, 因此 D 的输出结果趋近于 1/2。至此, 网络 G 和 D 处于纳什均衡状态, 无法再进一步优化。

整体算法的实现步骤:

如图所示:

Algorithm 1 Minibatch stochastic gradient descent training of generative adversarial nets. The number of steps to apply to the discriminator, k , is a hyperparameter. We used $k = 1$, the least expensive option, in our experiments.

for number of training iterations **do**

for k steps **do**

 • Sample minibatch of m noise samples $\{z^{(1)}, \dots, z^{(m)}\}$ from noise prior $p_g(z)$.

 • Sample minibatch of m examples $\{x^{(1)}, \dots, x^{(m)}\}$ from data generating distribution $p_{data}(x)$.

 • Update the discriminator by ascending its stochastic gradient:

$$\nabla_{\theta_d} \frac{1}{m} \sum_{i=1}^m \left[\log D(x^{(i)}) + \log (1 - D(G(z^{(i)}))) \right].$$

end for

 • Sample minibatch of m noise samples $\{z^{(1)}, \dots, z^{(m)}\}$ from noise prior $p_g(z)$.

 • Update the generator by descending its stochastic gradient:

$$\nabla_{\theta_g} \frac{1}{m} \sum_{i=1}^m \log (1 - D(G(z^{(i)}))).$$

end for

The gradient-based updates can use any standard gradient-based learning rule. We used momentum in our experiments.

首先, 用 k 步优化判别模型 D 的参数 θ_d 。然后, 固定 D, 优化生成模型 G 的参数 θ_g (采用反向传播来优化网络参数)。以上过程进行 n 次迭代。

相关数学证明:

当生成器 G 确定时, 判别器 D 的最优解为:

$$D_G^*(x) = \frac{p_{data}(x)}{p_{data}(x) + p_g(x)}$$

Proof.

$$\because \mathbb{E}_{x \sim p(x)} f(x) = \int_x p(x) f(x) dx$$

$$\therefore V(G, D) = \mathbb{E}_{x \sim p_{data}(x)} [\log D(x)] + \mathbb{E}_{z \sim p_z(z)} [\log (1 - D(G(z)))]$$

$$\begin{aligned}
&= \int_x p_{data}(x) \log D(x) dx + \int_z p_z(z) \log(1 - D(G(z))) dz \\
&= \int_x p_{data}(x) \log D(x) + p_g(x) \log(1 - D(x)) dx
\end{aligned}$$

\therefore 对于 $p_{data}(x) \log D(x) + p_g(x) \log(1 - D(x))$ 的最大值可近似于：

$f(y) = a \log y + b \log(1 - y)$, 对 $f(y)$ 求最大值

$$\because f'(y) = \frac{a}{y} - \frac{b}{1-y}, \text{ 且 } f(y) \text{ 为凸函数}$$

$$\therefore f(y) \text{ 的最大值为 } f'(y) = 0, \text{ 即 } y = \frac{a}{a+b}$$

$$\therefore D_G^*(x) = \frac{p_{data}(x)}{p_{data}(x) + p_g(x)}$$

得证。

下面求生成器 G 的最优解。

由于已知 $D_G^*(x)$ ，因此有：

$$\begin{aligned}
C(G) &= \max_D V(G, D) \\
&= \mathbb{E}_{x \sim p_{data}(x)} [\log D_G^*(x)] + \mathbb{E}_{z \sim p_z(z)} [\log(1 - D_G^*(G(z)))] \\
&= \mathbb{E}_{x \sim p_{data}(x)} [\log D_G^*(x)] + \mathbb{E}_{x \sim p_g(x)} [\log(1 - D_G^*(x))] \\
&= \mathbb{E}_{x \sim p_{data}(x)} \left[\log \frac{p_{data}(x)}{p_{data}(x) + p_g(x)} \right] + \mathbb{E}_{x \sim p_g(x)} \left[\log \frac{p_g(x)}{p_{data}(x) + p_g(x)} \right]
\end{aligned}$$

\therefore 对 $C(G)$ 求最小值，当且仅当 $p_{data}(x) = p_g(x)$ ，且值为 $-\log 4$

Proof.

$$\begin{aligned}
\because \log \frac{p_{data}}{p_{data} + p_g} &= \log \frac{p_{data}}{\frac{p_{data} + p_g}{2}} * \frac{1}{2} \\
&= \log \frac{p_{data}}{\frac{p_{data} + p_g}{2}} - \log 2
\end{aligned}$$

$$\text{又 } \because \mathbb{E}_{x \sim p_{data}} \left[\log \frac{p_{data}}{\frac{p_{data} + p_g}{2}} \right] = KL \left(p_{data} \parallel \frac{p_{data} + p_g}{2} \right)$$

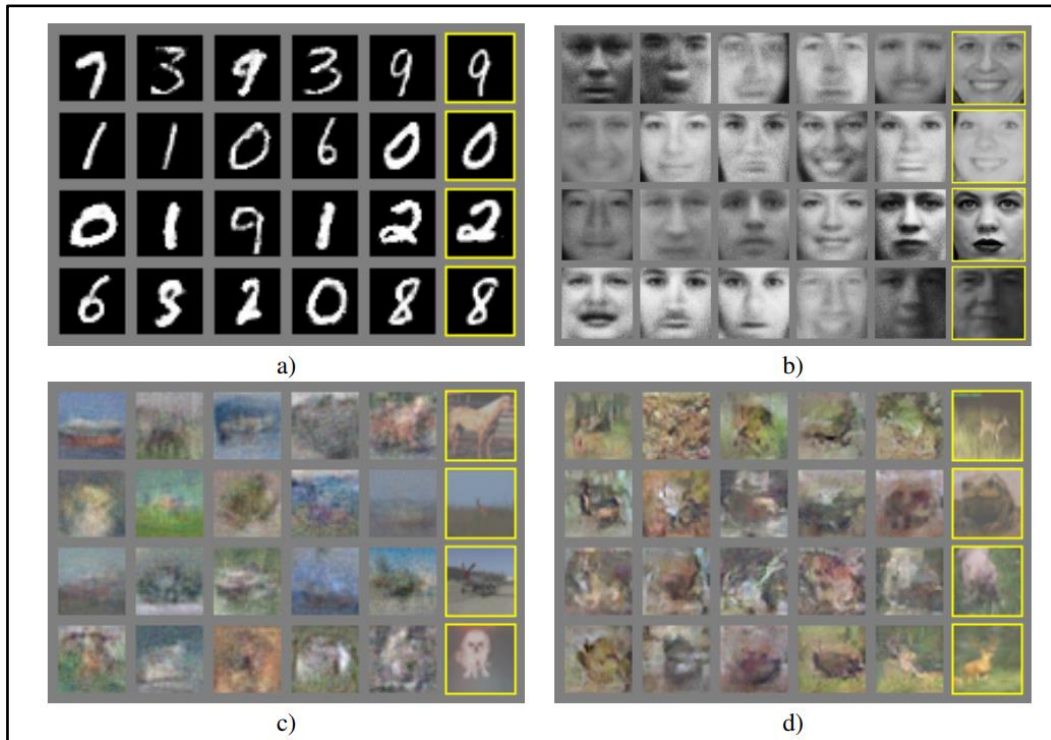
$$\therefore C(G) = -\log 4 + KL \left(p_{data} \parallel \frac{p_{data} + p_g}{2} \right) + KL \left(p_g \parallel \frac{p_{data} + p_g}{2} \right)$$

$$\because KL\left(p_{data} \parallel \frac{p_{data} + p_g}{2}\right) \geq 0, \text{ 且当 } p_{data} = \frac{p_{data} + p_g}{2} \text{ 时, 值为 } 0$$

$$\therefore C^* = -\log 4, \text{ 当且仅当 } p_{data}(x) = p_g(x)$$

得证。

实验结果:



注：最后一列为 G 生成的图片。

总结:

优点:

- 1) GAN 是一种以半监督方式训练分类器的方法。
- 2) G 的参数更新不是直接来自数据样本，而是使用来自 D 的反向传播。所以理论上，只要是可微分函数都可以用于构建 D 和 G。
- 3) GAN 可以比推理网络更快的产生样本，因为它不需要在采样序列下生成不同的数据。
- 4) GAN 框架只用到了反向传播，不涉及马尔科夫链。

缺点:

- 1) 训练 GAN 需要达到纳什均衡，虽然有时候可用梯度下降法做到，但有时

候却做不到，而本文还没有找到一个很好的达到纳什均衡的方法。

2) GAN 很难去学习、生成离散的数据，例如文本数据。

对本文的感悟：

GAN 的提出使得生成模型领域有了重大突破。作为一个开创性的方法（框架），它有效结合了博弈理论，并使得深度学习研究有了更宽阔的思路，以至于而后的研究者们在此之上做出了大量的改进和模型变种。